

Régression Linéaire Multiple

Bruno Pelletier

Outline

Modèle

Estimation

Propriétés des MCO

Prévision

Identifiabilité

Exercice

Modèle

Rappel : Modèle Linéaire Standard

On considère deux variables X et Y et l'on dispose d'observations (x_i, Y_i) , $i = 1, \dots, n$. Ecriture analytique :

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \forall i = 1, \dots, n.$$

Hypothèses :

- Centrage : $\mathbb{E}[\varepsilon_i] = 0$,
- Homoscédasticité : $\text{Var}(\varepsilon_i) = \sigma^2, \quad \forall i,$
- Décorrélation : $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j.$

Ecriture matricielle :

$$\mathbf{Y} = \mathbb{X}\beta + \boldsymbol{\epsilon},$$

avec

$$\mathbb{E}[\boldsymbol{\epsilon}] = 0 \quad \text{et} \quad \mathbb{V}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n.$$

Contexte multivarié

- Une variable réponse Y ,
- Variables explicatives : X_1, \dots, X_{p-1} .
- On inclut généralement une variable constante : $X_0 = 1$.
- Observations : (x_i, Y_i) , pour $i = 1, \dots, n$ avec

$$x_i = (x_{i,0}, \dots, x_{i,p-1}) \quad (\text{vecteur ligne}).$$

- Modèle (écriture analytique) :

$$Y_i = \beta_0 x_{i,0} + \beta_1 x_{i,1} + \dots + \beta_{p-1} x_{i,p-1} + \epsilon_i,$$

sous les hypothèses standard :

- (i) $\mathbb{E}[\epsilon_i] = 0 \ \forall i$,
- (ii) $\mathbb{V}(\epsilon_i) = \sigma^2 \ \forall i$,
- (iii) $\text{Cov}(\epsilon_i, \epsilon_j) = 0 \ \forall i \neq j$.

Ecriture matricielle du modèle

On pose :

$$\begin{aligned}\mathbf{Y} &= (Y_1, \dots, Y_n)', && (\text{vecteur aléatoire de } \mathbb{R}^n) \\ \boldsymbol{\epsilon} &= (\epsilon_1, \dots, \epsilon_n)', && (\text{vecteur aléatoire de } \mathbb{R}^n) \\ \boldsymbol{\beta} &= (\beta_0, \dots, \beta_{p-1})', && (\text{vecteur de paramètres de } \mathbb{R}^p) \\ \mathbb{X} &= \begin{bmatrix} x_{1,0} & \cdots & x_{1,p-1} \\ \vdots & \vdots & \vdots \\ x_{n,0} & \cdots & x_{n,p-1} \end{bmatrix} && (\text{matrice de taille } n \times p)\end{aligned}$$

Modèle (écriture matricielle) :

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\epsilon},$$

sous les hypothèses standard :

$$\mathbb{E}[\boldsymbol{\epsilon}] = 0 \quad \text{et} \quad \mathbb{V}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n.$$

Estimation

Estimation par Moindres Carrés Ordinaires

Le critère des moindres carrés s'écrit :

$$\mathcal{L}(\beta) = \sum_{i=1}^n (Y_i - (\beta_0 x_{i,0} + \beta_1 x_{i,1} + \cdots + \beta_{p-1} x_{i,p-1}))^2.$$

En notations matricielles :

$$\mathcal{L}(\beta) = \|\mathbf{Y} - \mathbb{X}\beta\|^2.$$

On cherche à construire un estimateur $\hat{\beta}$ en minimisant $\mathcal{L}(\beta)$ par rapport à β sur \mathbb{R}^p .

- \mathcal{L} admet-elle un minimum sur \mathbb{R}^p ? Si oui, est-il unique ?

Différentiation de $\mathcal{L}(\beta)$

On a

$$\begin{aligned}\mathcal{L}(\beta) &= \|\mathbf{Y} - \mathbb{X}\beta\|^2 \\ &= \|\mathbf{Y}\|^2 - 2\langle \mathbf{Y}, \mathbb{X}\beta \rangle + \|\mathbb{X}\beta\|^2 \\ &= \|\mathbf{Y}\|^2 - 2\mathbf{Y}'\mathbb{X}\beta + (\mathbb{X}\beta)'(\mathbb{X}\beta) \\ &= \|\mathbf{Y}\|^2 - 2\mathbf{Y}'\mathbb{X}\beta + \beta'\mathbb{X}'\mathbb{X}\beta.\end{aligned}$$

D'où l'expression du **gradient de \mathcal{L}** :

$$\nabla \mathcal{L}(\beta) = 2\mathbb{X}'\mathbb{X}\beta - 2\mathbb{X}'\mathbf{Y}.$$

Remarque : différentiation d'une forme linéaire et d'une forme quadratique.

Point critique de $\mathcal{L}(\beta)$

$$\nabla \mathcal{L}(\beta) = 0 \iff \underbrace{\mathbb{X}'\mathbb{X}\beta}_{\text{Equations normales}} = \mathbb{X}'\mathbf{Y} .$$

$\mathbb{X}'\mathbb{X}$ est une matrice symétrique de taille $p \times p$, et si elle est inversible, on obtient l'estimateur (unique) des MCO de β :

$$\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1} \mathbb{X}'\mathbf{Y}.$$

Remarques :

- $(\mathbb{X}'\mathbb{X})$ est inversible si \mathbb{X} est de rang plein (i.e., p ; on suppose $n \geq p$).
- On vérifie qu'il s'agit bien d'un minimum.

Valeurs ajustées

Pour la $i^{\text{ème}}$ observation, la valeur prédite par le modèle est :

$$\hat{Y}_i = \hat{\beta}_0 x_{i,0} + \hat{\beta}_1 x_{i,1} + \cdots + \hat{\beta}_{p-1} x_{i,p-1}.$$

On introduit le **vecteur des valeurs ajustées** :

$$\hat{\mathbf{Y}} = (\hat{Y}_1, \dots, \hat{Y}_n)' = \mathbb{X}\hat{\beta}.$$

D'où :

$$\begin{aligned}\hat{\mathbf{Y}} &= \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbf{Y} \\ &= \Pi_{\text{Im}(\mathbb{X})}\mathbf{Y},\end{aligned}$$

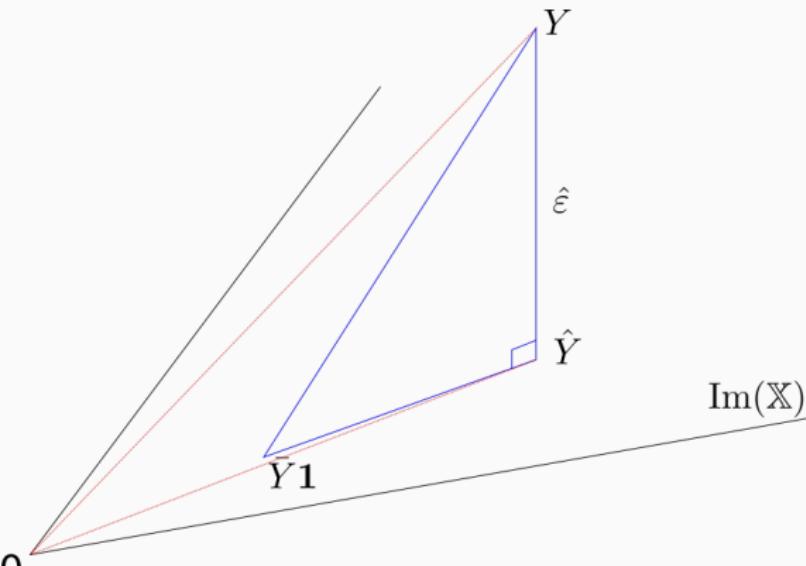
où

$$\Pi_{\text{Im}(\mathbb{X})} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'$$

est la **matrice de projection sur $\text{Im}(\mathbb{X})$** dans \mathbb{R}^n .

Résidus

Vecteur des résidus : $\hat{\epsilon} = (\epsilon_1, \dots, \epsilon_n)' = \mathbf{Y} - \hat{\mathbf{Y}}$.



$$\|\mathbf{Y}\|^2 = \|\hat{\mathbf{Y}}\|^2 + \|\hat{\epsilon}\|^2 \quad (\text{toujours vraie})$$

$$\|\mathbf{Y} - \bar{Y}\mathbf{1}\|^2 = \|\hat{\mathbf{Y}} - \bar{Y}\mathbf{1}\|^2 + \|\hat{\epsilon}\|^2 \quad (\text{lorsque modèle avec constante})$$

Coefficient de détermination R^2

$$\begin{aligned} R^2 &= \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}} \\ &= \begin{cases} \frac{\|\hat{\mathbf{Y}}\|^2}{\|\mathbf{Y}\|^2} & \text{si modèle sans constante} \\ \frac{\|\hat{\mathbf{Y}} - \bar{Y}\mathbf{1}\|^2}{\|\mathbf{Y} - \bar{Y}\mathbf{1}\|^2} & \text{si modèle avec constante} \end{cases} \end{aligned}$$

Le R^2 ne tient pas compte du nombre de paramètres du modèle. Coefficient de détermination ajusté R_a^2 :

$$R_a^2 = \begin{cases} 1 - \frac{n}{n-p} \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{n}{n-p} (1 - R^2) & \text{modèle sans constante} \\ 1 - \frac{n-1}{n-p} \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{n-1}{n-p} (1 - R^2) & \text{modèle avec constante} \end{cases}$$

Remarque : Logiciel R : "R-squared" et "Multiple R-squared".

Propriétés des MCO

Espérance de $\hat{\beta}$

$$\mathbb{E}[\hat{\beta}] = \mathbb{E}\left[\underbrace{(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'}_{\text{déterministe}} \mathbf{Y}\right] = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{E}[\mathbf{Y}].$$

$$\mathbb{E}[\mathbf{Y}] = \mathbb{E}[\mathbb{X}\beta + \epsilon] = \mathbb{X}\beta + \mathbb{E}[\epsilon] = \mathbb{X}\beta.$$

D'où :

$$\mathbb{E}[\hat{\beta}] = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}\beta = \beta.$$

Conclusion : $\hat{\beta}$ est un estimateur sans biais de β .

Matrice de covariance de $\hat{\beta}$

Rappel : Covariance

Pour \mathbf{A} une matrice déterministe et \mathbf{Y} un vecteur aléatoire :

$$\begin{aligned}\mathbb{V}(\mathbf{Y}) &= \mathbb{E}[\mathbf{Y}\mathbf{Y}'] - \mathbb{E}[\mathbf{Y}]\mathbb{E}[\mathbf{Y}]' \\ \mathbb{V}(\mathbf{AY}) &= \mathbf{A} \mathbb{V}(\mathbf{Y}) \mathbf{A}'.\end{aligned}$$

$$\mathbb{V}(\hat{\beta}) = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' \mathbb{V}(\mathbf{Y}) [(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}']'.$$

Or : $\mathbb{V}(\mathbf{Y}) = \mathbb{V}(\mathbb{X}\beta + \epsilon) = \mathbb{V}(\epsilon) = \sigma^2 \mathbf{I}_n,$

et : $\sigma^2(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' [(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}']' = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X} [(\mathbb{X}'\mathbb{X})^{-1}]' = (\mathbb{X}'\mathbb{X})^{-1}.$

D'où : $\mathbb{V}(\hat{\beta}) = \sigma^2(\mathbb{X}'\mathbb{X})^{-1}$

Prévision

Prévision

- Modèle : $Y_i = \beta_0 x_{i,0} + \beta_1 x_{i,1} + \cdots + \beta_{i,p-1} x_{i,p-1} + \epsilon_i$.
- Nouvelle donnée : $x_{n+1} = (x_{n+1,0}, \dots, x_{n+1,p-1})$, observée.
- Modèle étendu :
$$Y_{n+1} = \beta_0 x_{n+1,0} + \cdots + \beta_{p-1} x_{n+1,p-1} + \epsilon_{n+1}$$
, (non observée).
- Objectif : prédire la valeur de Y_{n+1} à partir de x_{n+1} .
- Hypothèses : $\mathbb{E}[\epsilon_{n+1}] = 0$, $\mathbb{V}(\epsilon_{n+1}) = \sigma^2$, $\text{Cov}(\epsilon_i, \epsilon_{n+1}) = 0$
 $\forall i = 1, \dots, n$.
- Valeur prédictive :
$$\hat{Y}_{n+1}^{(p)} = x_{n+1} \beta$$
- Erreur de prévision :

$$\hat{\epsilon}_{n+1}^{(p)} = Y_{n+1} - \hat{Y}_{n+1}^{(p)}$$

Propriétés de l'erreur de prévision

- $\mathbb{E} [\hat{\epsilon}_{n+1}^{(p)}] = \mathbb{E} [Y_{n+1}] - \mathbb{E} [\hat{Y}_{n+1}^{(p)}] = x_{n+1}\beta - x_{n+1} \underbrace{\mathbb{E} [\hat{\beta}]}_{=\beta} = 0.$
- $\mathbb{V} (\hat{\epsilon}_{n+1}^{(p)}) = \mathbb{V} (Y_{n+1}) + \mathbb{V} (\hat{Y}_{n+1}^{(p)}) - 2 \underbrace{\text{Cov} (Y_{n+1}, \hat{Y}_{n+1}^{(p)})}_{=0}$
- En effet : $\hat{Y}_{n+1}^{(p)} \in \sigma\{\epsilon_1, \dots, \epsilon_n\}$ tandis que $Y_{n+1} \in \sigma\{\epsilon_{n+1}\}$.
- $$\begin{aligned} \mathbb{V} (\hat{\epsilon}_{n+1}^{(p)}) &= \sigma^2 + \mathbb{V} (x_{n+1}\hat{\beta}) = \sigma^2 + x_{n+1} \mathbb{V} (\hat{\beta}) x'_{n+1} \\ &= \sigma^2 + x_{n+1} \sigma^2 (\mathbb{X}' \mathbb{X})^{-1} x'_{n+1} \\ &= \sigma^2 [1 + x_{n+1} (\mathbb{X}' \mathbb{X})^{-1} x'_{n+1}] . \end{aligned}$$

Identifiabilité

Identifiabilité

- Modèle : $\mathbf{Y} = \mathbb{X}\beta + \epsilon$.
- MCO : $\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbf{Y}$.
- Est-il toujours possible d'estimer β ?
- Exemple : Soit la matrice de design suivante

$$\mathbb{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

$$\mathbb{X} \sim \begin{bmatrix} 1 & 1 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \\ 0 & -1 & 1 \end{bmatrix} \sim \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

\mathbb{X} est de rang 2, donc $\mathbb{X}'\mathbb{X}$ n'est pas inversible.

Équations normales

- Critère des MCO : $\mathcal{L}(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2$.
- $\nabla \mathcal{L}(\beta) = 0 \iff \mathbf{X}'\mathbf{X}\beta = \mathbf{X}'\mathbf{Y}$.
- Lorsque $\mathbf{X}'\mathbf{X}$ n'est pas inversible les équations normales admettent une infinité de solutions (un s.e.v.).
- Le modèle est dit **identifiable** si $\mathbf{X}\alpha_1 = \mathbf{X}\alpha_2 \implies \alpha_1 = \alpha_2$
 $\forall \alpha_1, \alpha_2 \in \mathbb{R}^p$.
- Néanmoins, peut-on estimer certaines composantes de β ?
Ou bien certaines combinaisons linéaires de β ?

Il est possible d'estimer $\langle a, \beta \rangle$ si cette combinaison est identifiable, i.e., si $\mathbf{X}\alpha_1 = \mathbf{X}\alpha_2 \implies \langle a, \alpha_1 \rangle = \langle a, \alpha_2 \rangle$,
 $\forall \alpha_1, \alpha_2 \in \mathbb{R}^p$.

Identifiabilité d'une combinaison linéaire $\langle a, \beta \rangle$

$$[\mathbb{X}\alpha_1 = \mathbb{X}\alpha_2 \implies \langle a, \alpha_1 \rangle = \langle a, \alpha_2 \rangle, \quad \forall \alpha_1, \alpha_2 \in \mathbb{R}^p]$$

$$\iff [\mathbb{X}(\alpha_1 - \alpha_2) = 0 \implies \langle a, \alpha_1 - \alpha_2 \rangle = 0, \quad \forall \alpha_1, \alpha_2 \in \mathbb{R}^p]$$

$$\iff [\mathbb{X}u = 0 \implies \langle a, u \rangle = 0, \quad \forall u \in \mathbb{R}^p]$$

$$\iff [\langle a, u \rangle = 0, \quad \forall u \in \text{Ker}(\mathbb{X})]$$

$$\iff a \in \text{Ker}(\mathbb{X})^\perp$$

$$\iff a \in \text{Row}(\mathbb{X}).$$

La combinaison linéaire $\langle a, \beta \rangle$ est identifiable si a appartient à l'espace engendré par les lignes de \mathbb{X} .

Exemple

$$\mathbb{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \sim \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Donc

$$\text{Row}(\mathbb{X}) = \text{Vect} \{[1 \ 1 \ 0], [0 \ 1 \ -1]\}.$$

- Par exemple, il est possible d'estimer $\beta_0 + \beta_1$ car

$$\beta_0 + \beta_1 = \langle \beta, [1 \ 1 \ 0]' \rangle.$$

- Est-il possible d'estimer β_0 ?

De manière équivalente : $[1 \ 0 \ 0]$ appartient-il à $\text{Row}(\mathbb{X})$? ...Non.

Exercice

Exercice 1 (Deux variables explicatives)

On souhaite expliquer une variable réponse y à partir de deux variables explicatives x et z . Soit $\mathbb{X} = [\mathbf{1} \ x \ z]$ la matrice $n \times 3$ du plan d'expériences qui satisfait les relations suivantes :

$$\mathbb{X}'\mathbb{X} = \begin{pmatrix} 25 & 0 & 0 \\ ? & 9.3 & 5.4 \\ ? & ? & 12.7 \end{pmatrix} \quad (\mathbb{X}'\mathbb{X})^{-1} = \begin{pmatrix} 0.04 & 0 & 0 \\ 0 & 0.1428 & -0.0607 \\ 0 & -0.0607 & 0.1046 \end{pmatrix}.$$

1. Donner les valeurs manquantes.
2. Que vaut n ?
3. Calculer le coefficient de corrélation empirique entre x et z .
4. L'ajustement linéaire donne

$$y = -1.61 + 0.61x + 0.46z + \hat{\epsilon}, \quad SCR = \|\hat{\epsilon}\|^2 = 0.3.$$

- Déterminer la valeur de la moyenne empirique \bar{y} .
- Calculer la somme des carrés expliqués (SCE), la somme des carrés totale (SCT), le coefficient de détermination et le coefficient de détermination ajusté.