

# Validation et détection des écarts

---

Bruno Pelletier

# Outline

Introduction

Etude des résidus

Etude de la matrice chapeau

Mesures d'influence

Autres diagnostics

# Introduction

---

# Hypothèses du modèle linéaire

## Modèle

$$\mathbf{Y} = \mathbb{X}\beta + \epsilon.$$


## Hypothèses

1. Bruits centrés :  $\mathbb{E}[\epsilon] = 0$
2. Homoscédasticité :  $\mathbb{V}(\epsilon_i) = \sigma^2, \forall i = 1, \dots, n.$
3. Décorrélation :  $\text{Cov}(\epsilon_i, \epsilon_j) = 0, \forall i \neq j.$
4. Hypothèse gaussienne :  $\epsilon \sim \mathcal{N}_n(0, \sigma^2, \mathbf{I}_n).$

## Questions


- Les hypothèses sont-elles satisfaites ?
- Certaines observations sont-elles "atypiques", susceptibles d'invalider le modèle ?

# Exemple




~ situation "normale".

## Exemple




↔ deux données aberrantes.

## Exemple



~> défaut de décorrélation

## Exemple



~~> défaut d'homoscédasticité.

## Etude des résidus

---



# Etude des résidus

- L'examen des résidus constitue une étape primordiale de la régression linéaire.
- Les méthodes sont principalement graphiques. Il est difficile d'énoncer des règles strictes.



## Rappels

- Résidus :  $\hat{\epsilon}_i = y_i - \hat{y}_i$  et  $\hat{\epsilon} = \mathbf{Y} - \hat{\mathbf{Y}}$ .

## Exemple : situation "normale"





## Exemple : données aberrantes/atypiques





- Deux résidus ont des valeurs anormalement élevées, par rapport aux autres.
- Détection statistique :  $\rightsquigarrow$  calibration, test.

## Exemple : défaut de décorrélation



- Motif "non linéaire" visible sur ces graphiques.
- Causes possibles : bruits autorégressifs, dépendance non linéaire en une variable explicative.

## Exemple : défaut d'homoscédasticité



- Tendance de variance croissante avec la variable explicative.
- Hétéroscédaстicité des résidus.

# Etude des résidus

## Modèle gaussien

- Observations :  $\mathbf{Y} = \mathbb{X}\beta + \epsilon$ , où  $\epsilon \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I}_n)$ .
- Valeurs ajustées :  $\hat{\mathbf{Y}} = \mathbb{X}\hat{\beta} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbf{Y} = \mathbf{H}\mathbf{Y}$ , où

$$\mathbf{H} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}',$$

est la matrice de projection sur  $\text{Im}(\mathbb{X})$  et s'appelle la **matrice chapeau (hat matrix)**. Notons  $\mathbf{H} = [h_{ij}]_{1 \leq i, j \leq n}$ .

## Résidus

- Résidus :  $\hat{\epsilon} = \mathbf{Y} - \hat{\mathbf{Y}}$ .
- Sous les hypothèses standard du modèle gaussien :
  - $\hat{\epsilon}$  suit une loi gaussienne
  - $\mathbb{E}[\hat{\epsilon}] = 0$  et  $\mathbb{V}(\hat{\epsilon}) = \sigma^2(\mathbf{I} - \mathbf{H})$ .

$$\rightsquigarrow \hat{\epsilon}_i \sim \mathcal{N}(0, \sigma^2(1 - h_{ii})).$$

## Résidus studentisés

- $\hat{\epsilon}_i \sim \mathcal{N}(0, \sigma^2(1 - h_{ii})).$
- Donc

$$\frac{\hat{\epsilon}_i}{\sigma\sqrt{1 - h_{ii}}} \sim \mathcal{N}(0, 1).$$

## Résidus studentisés

$$r_i^* = \frac{\hat{\epsilon}_i}{\hat{\sigma}\sqrt{1 - h_{ii}}} \underset{\text{approx.}}{\sim} \mathcal{T}(n - p).$$

## Remarques

- Les résidus studentisés ne suivent pas exactement une loi de Student.
- $\hat{\epsilon}$  et  $\hat{\sigma}$  ne sont pas indépendants.
- Les  $r_i^*$  ont une variance approxmativement égale à 1.

## Résidus studentisés par validation croisée

1. Ajuster un modèle linéaire sur les  $n$  observations pour former les résidus  $\hat{\epsilon}_i$ .
2. Pour chaque  $i = 1, \dots, n$  :
  - 2.1 Ajuster un modèle linéaire sur toutes les observations sauf la  $i^{\text{ème}}$ .
  - 2.2 Noter  $\hat{\sigma}_{(i)}^2$  l'estimateur sans biais de la variance résultant.
  - 2.3 Définir

$$t_i^* = \frac{\hat{\epsilon}_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}}.$$

Théorème (Résidus studentisés par validation croisée)

$$t_i^* \sim \mathcal{T}(n - p - 1).$$

**Remarque**

On montre que

$$t_i^* = r_i^* \sqrt{\frac{n - p - 1}{n - p - (r_i^*)^2}}.$$

# Utilisation des résidus studentisés.



## Donnée aberrante

Une donnée  $(x_i, y_i)$  est considérée comme **aberrante** si son résidu studentisé par validation croisée  $t_i^*$  excède un seuil relatif à la loi de Student  $\mathcal{T}(n - p - 1)$ , par exemple si  $|t_i^*| > t_{n-p-1}(1 - \alpha/2)$ .

## Remarque :

- En pratique, si  $n - p - 1 \geq 30$ , avec  $\alpha = 5\%$ ,  
 $t_{n-p-1}(1 - \alpha/2) \approx 2$ .
- Diagnostic graphique : tracés des résidus studentisés par VC en fonction de  $i$ , ou d'une variable explicative ou des valeurs ajustées  $\hat{y}_i$ .

## Exemple : donnée aberrante



~~~ trois observations sont détectées comme aberrantes.

# Analyse de la normalité

## Outils graphiques

- Histogramme des résidus studentisés  $t_i^*$ .
- Tracés des  $t_i^*$  en fonction de l'espérance de ces quantiles sous l'hypothèse de normalité (Q-Q plot).

## Mesure diagnostique

- Test de normalité de Shapiro-Wilk.

### Remarque

Les  $t_i^*$  suivent une loi de Student et ne sont pas indépendants. Néanmoins, si  $n$  est grand et  $n$  est grand devant  $p$ , alors cette loi est proche d'une loi  $\mathcal{N}(0, 1)$ .

## Outils graphiques

- Tracés des résidus studentisés  $t_i^*$  en fonction des valeurs ajustées  $\hat{y}_i$ .
- Selon le problème, tracé des  $t_i^*$  en fonction d'autres variables.
- Déetecter la présence d'une structure (tendance croissante, décroissante, oscillante, etc.)
- Estimer la courbe de régression de  $t_i^*$  sur  $\hat{y}_i$  par polynômes locaux par exemple.

## Mesure diagnostique

- Test de Breusch et Pagan : détection de l'hétéroscédasticité.
- Test de Durbin Watson : détection d'une auto-corrélation.

## Etude de la matrice chapeau

---

# Influence d'une observation

## Question

Quelle est l'influence d'une observation  $x_i$  sur l'ajustement de  $Y_i$  dans le modèle ?

- $y_i$  est prédit par  $\hat{y}_i$  et le résidu associé est  $\hat{\epsilon}_i \sim \mathcal{N}(0, \sigma^2(1 - h_{ii}))$ .

↔ Dépendance de la variance des résidus en les variables explicatives au travers des éléments  $h_{ii}$ .

- $\hat{Y}_i = \sum_{j=1}^n h_{ij} Y_j = \textcolor{brown}{h}_{ii} Y_i + \sum_{j \neq i} h_{ij} Y_j$ .

↔  $h_{ii}$  traduit l'influence de  $Y_i$  sur sa valeur prédictive  $\hat{Y}_i$ .

# Influence d'une observation

## Ajustement sur les $n$ observations

- La valeur ajustée est  $\hat{Y}_i$
- L'erreur (résidu) est  $Y_i - \hat{Y}_i$ .

## Ajustement sur toutes les observations sauf la $i^{\text{ème}}$ .

- Ce modèle est utilisé pour prédire  $Y_i$  à partir de  $x_i$ .
- On note  $\hat{Y}_i^{(p)}$  la valeur prédictive.
- L'erreur en prévision est  $Y_i - \hat{Y}_i^{(p)}$ .

## Propriété

$$Y_i - \hat{Y}_i = (1 - h_{ii})(Y_i - \hat{Y}_i^{(p)}).$$

↔ variation dans l'erreur de prévision selon que la  $i^{\text{ème}}$  observation est prise en compte ou non.

# Propriétés de la matrice chapeau

Hat matrix (matrice de projection orthogonale sur  $\text{Im}(\mathbb{X})$ )

Soit  $\mathbf{H} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'$ .

## Propriété 1

$\mathbf{H}$  est idempotente :  $\mathbf{H}^2 = \mathbf{H}$ .

En effet  $\mathbf{H} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = \mathbf{H}$ .

Il en résulte que  $\text{tr}(\mathbf{H}^2) = \text{tr}(\mathbf{H})$ .

- D'une part :  $\text{tr}(\mathbf{H}^2) = \sum_{i=1}^n \sum_{j=1}^n h_{ij}h_{ji} = \sum_{i,j=1}^n h_{ij}^2$  car  $\mathbf{H}$  est symétrique.
- D'autre part :  $\text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii}$ . En outre

$$\text{tr}(\mathbf{H}) = \text{tr}(\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}') = \text{tr}((\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}) = \text{tr}(\mathbf{I}_p) = p.$$

$$\rightsquigarrow \sum_{i,j=1}^n h_{ij}^2 = \sum_{i=1}^n h_{ii} = p.$$

## Propriétés de la matrice chapeau

### Propriété 2

$$0 \leq h_{ii} \leq 1$$

Soit  $e_i$  le  $i^{\text{ème}}$  vecteur de la base canonique de  $\mathbb{R}^n$ . On a :

$$h_{ii} = e_i' \mathbf{H} e_i = e_i' \mathbf{H}^2 e_i = e_i' \mathbf{H}' \mathbf{H} e_i = \|\mathbf{H} e_i\|^2 \geq 0.$$

$\mathbf{H}$  étant une matrice de projection,  $\|\mathbf{H} u\| \leq \|u\|$  pour tout  $u \in \mathbb{R}^n$ . Donc  $\|\mathbf{H} e_i\| \leq \|e_i\| = 1$  et donc  $h_{ii} \leq 1$ .

↔ cas extrémaux :  $h_{ii} = 0$  et  $h_{ii} = 1$ .

## Cas extrémaux

**Cas  $h_{ii} = 0$**

On a  $h_{ii} = \|\mathbf{H}\mathbf{e}_i\|^2 = \sum_{j=1}^n h_{ji}^2$ . Donc

$$h_{ij} = h_{ji} = 0 \quad \text{pour tout } j = 1, \dots, n.$$

Conséquence

$$\hat{Y}_i = \sum_{j=1}^n h_{ij} Y_j = 0.$$

$\rightsquigarrow Y_i$  n'a pas d'influence sur  $\hat{Y}_i$ .

## Cas extrémaux

### Cas $h_{ii} = 1$

Comme  $\mathbf{H}$  est idempotente, on a

$$h_{ii} = \sum_{j=1}^n h_{ji}^2 = h_{ii}^2 + \sum_{j \neq i} h_{ji}^2. \text{ Donc}$$

$$h_{ij} = h_{ji} = 0 \quad \text{pour tout } j \neq i.$$

### Conséquence

$$\hat{Y}_i = \sum_{j=1}^n h_{ij} Y_j = Y_i.$$

$\rightsquigarrow \hat{Y}_i$  est entièrement déterminée par  $Y_i$ .

## Effet levier

Ainsi  $\hat{Y}_i$  est d'autant plus influencée par  $Y_i$  que  $h_{ii}$  est proche de 1. Seuil ?



On a montré que  $\sum_{i=1}^n h_{ii} = p$ , donc la valeur moyenne des  $h_{ii}$  est  $\frac{p}{n}$ .

### Définition (Effet levier)

On dit que la donnée  $(x_i, y_i)$  a un **effet levier** si :

- $h_{ii} \geq 2p/n$  (Hoaglin and Welsh, 1978).
- $h_{ii} \geq 3p/n$  pour  $p > 6$  et  $n - p > 12$  (Velleman and Welsh, 1981).
- $h_{ii} \geq 1/2$  (Huber, 1981).

## Exemple : effet levier



~~ Un point a un effet levier, mais n'est pas un point aberrant.

## Résumé : donnée aberrante et effet levier

### Donnée aberrante

Si  $|t_i^*| > t_{n-p-1}(1 - \alpha/2)$ .

~ donnée atypique par rapport à la variable réponse.

### Effet levier

Si  $h_{ii} > cp/n$ , pour  $c = 2$  ou  $c = 3$ .

~ donnée atypique par rapport aux variables explicatives.

## Mesures d'influence

---

# Influence sur l'estimation de $\beta$

Quelle est l'influence des données aberrantes à effet levier sur l'estimation des paramètres du modèle ?

## Approche

1. Estimer  $\beta$  à partir de toutes les observations :  $\rightsquigarrow \hat{\beta}$ .
2. Estimer  $\beta$  à partir de toutes les observations sauf la  $i^{\text{ème}}$  :  
 $\rightsquigarrow \hat{\beta}^{(i)}$ .
3. Former une mesure de distance entre  $\hat{\beta}$  et  $\hat{\beta}^{(i)}$ , par exemple de la forme  $(\hat{\beta} - \hat{\beta}^{(i)})' A (\hat{\beta} - \hat{\beta}^{(i)})$  avec  $A \in \mathcal{M}_{p,p}(\mathbb{R})$  symétrique et définie positive, i.e. induite par un produit scalaire dans  $\mathbb{R}^p$ .

Rappel : Ellipsoïde de confiance de niveau  $1 - \alpha$  sur  $\beta$ .

$$I_{1-\alpha} = \left\{ \beta \in \mathbb{R}^p : \frac{1}{p\sigma^2} (\hat{\beta} - \beta)' \mathbb{X}' \mathbb{X} (\hat{\beta} - \beta) \leq f_{p,n-p}(1 - \alpha) \right\}.$$

# Distance de Cook

## Distance de Cook

La distance de Cook pour la  $i^{\text{ème}}$  observation est définie par :

$$C_i = \frac{1}{p\hat{\sigma}^2} (\hat{\beta}^{(i)} - \hat{\beta})' \mathbb{X}' \mathbb{X} (\hat{\beta}^{(i)} - \hat{\beta}).$$

## Propriété

$$C_i = \frac{1}{p} \frac{h_{ii}}{(1-h_{ii})^2} \frac{\hat{\epsilon}_i^2}{\hat{\sigma}^2} = \frac{1}{p} \frac{h_{ii}}{1-h_{ii}} (r_i^*)^2.$$





## Interprétation

$C_i$  est élevée si  $(x_i, y_i)$  influence fortement l'estimation de  $\beta$ .


En outre,  $C_i$  est potentiellement élevée si :

- $|r_i^*|$  est élevé  $\rightsquigarrow$  donnée aberrante,
- $h_{ii}$  est proche de 1  $\rightsquigarrow$  point levier.
- les deux.

# Exemple






$$\text{CalCOFI (1)} : y = \beta_0 + \beta_1 x + \epsilon_i$$




- Droite de régression :  $y = 169.1178 - 4.79646x$ .
- $R^2 = 0.8517$ .

# CalCOFI (1) : analyse des résidus






Sahapiro-Wilk's normality test  
p-value : 0.001155

CalCOFI (2) :  $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon_i$



- Ajustement :  $y = -3387.5941 + 207.3393x - 3.1622x^2$ .
- $R^2 = 0.9138$ .


## CalCOFI (2) : analyse des résidus



Sapiro-Wilk's normality test  
p-value : 0.08177


# CalCOFI (2) : analyse des résidus

Fitted values



Seuil à  $3p/n$

Cook's distances



Quantile d'ordre 10%

## Autres diagnostics

---

# Influence non linéaire : résidus partiels

## Modèle linéaire

$$Y_i = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_j x_{i,j} + \cdots + \beta_{p-1} x_{i,p-1} + \epsilon_i.$$

$$\text{Résidus : } \hat{\epsilon}_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i,1} + \cdots + \hat{\beta}_{p-1} x_{i,p-1}).$$

## Résidu partiel pour la $j^{\text{ème}}$ variable

$$\hat{e}_i^j = \hat{\epsilon}_i + \hat{\beta}_j x_{i,j}.$$

## Diagnostic pour la $j^{\text{ème}}$ variable


- Tracer les résidus partiels  $\hat{e}_i^j$  en fonction des  $x_{i,j}$ .
- En effet, une régression linéaire sans constante pour expliquer  $\hat{e}_i^j$  à partir des  $x_{i,j}$  donne une pente égale à :

$$\frac{\langle \hat{e}_i^j, X^j \rangle}{\|X^j\|^2} = \hat{\beta}_j.$$

## Exemple : tracés des résidus partiels

Soient des observations  $(x_{i,1}, x_{i,2}, Y_i)$  issues du modèle

$$Y_i = 4 - x_{i,1} + 3x_{i,2}^2 + \epsilon_i.$$



↔ Identification de l'influence non linéaire de  $X^2$ .